

分类号 _____

密 级 _____

U D C _____

编 号 10486

武汉大学

硕 士 学 位 论 文
(学术学位)

论文题目，楷体一号

研 究 生 姓 名：张 三

学 号：2021202012345

校内导师姓名、职称：李 某 某 教 授

学 科、专 业 名 称：英 语、英 国 语 言 文 学

研 究 方 向：英 语 语 言 学

二〇二四年四月

A QoS-aware Self-Adaptive System Approach in Service Computing Environment

Candidate: XXXXXX XXXXX

Student number: 2021202012345

Supervisor: PROF. XXX XXXXX

Major: English language and literature

Speciality: Operator Theory



School of Mathematics and Statistics
WUHAN UNIVERSITY

Apr, 2024

论文原创性声明

本人郑重声明：所呈交的学位论文，是本人在导师指导下，独立进行研究工作所取得的研究成果。除文中已经标明引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写过的研究成果。对本文的研究做出贡献的个人和集体，均已在文中以明确方式标明。本声明的法律结果由本人承担。

学位论文作者（签名）：

年 月 日

摘 要

论文的摘要是对论文研究内容和成果的高度概括。摘要应对论文所研究的问题及其研究目的进行描述，对研究方法和过程进行简单介绍，对研究成果和所得结论进行概括。摘要应具有独立性和自明性，其内容应包含与论文全文同等量的主要信息。使读者即使不阅读全文，通过摘要就能了解论文的总体内容和主要成果。

论文摘要的书写应力求精确、简明。切忌写成对论文书写内容进行提要的形式，尤其要避免“第 1 章……；第 2 章……；……”这种或类似的陈述方式。

关键词是为了文献标引工作、用以表示全文主要内容信息的单词或术语。关键词不超过 5 个，每个关键词中间用分号分隔。

关键词：LaTeX；毕业论文；模版；武汉大学

ABSTRACT

An abstract of a dissertation is a summary and extraction of research work and contributions. Included in an abstract should be description of research topic and research objective, brief introduction to methodology and research process, and summary of conclusion and contributions of the research. An abstract should be characterized by independence and clarity and carry identical information with the dissertation. It should be such that the general idea and major contributions of the dissertation are conveyed without reading the dissertation.

An abstract should be concise and to the point. It is a misunderstanding to make an abstract an outline of the dissertation and words “the first chapter”, “the second chapter” and the like should be avoided in the abstract.

Keywords are terms used in a dissertation for indexing, reflecting core information of the dissertation. An abstract may contain a maximum of 5 keywords, with semi-colons used in between to separate one another.

Keywords: L^AT_EX; Thesis; Template; Wuhan University

目 录

摘 要	I
ABSTRACT	III
1 引言	1
1.1 研究背景与问题定义	1
1.1.1 移动端本地推理的现实需求	1
1.1.2 异构多核 CPU 上的执行复杂性	1
1.1.3 MNN 默认执行方式下的工程瓶颈	2
1.2 研究动机与核心问题	2
1.2.1 绑核与线程数选择对性能的影响	2
1.2.2 固定性能比静态划分的局限	2
1.2.3 高负载场景下的阻塞与长尾问题	3
1.3 本文工作与贡献	3
1.3.1 分阶段绑核与线程数启发式搜索	3
1.3.2 基于真实性能比的加权初始划分	4
1.3.3 基于无锁双端队列的 Prefill work stealing 机制	4
1.4 论文组织结构	4
1.4.1 章节安排	4
1.4.2 写作定位说明	4
参考文献	5

1 引言

1.1 研究背景与问题定义

1.1.1 移动端本地推理的现实需求

近年来，大语言模型和多模态模型逐步从云侧走向端侧。手机、平板和便携式边缘设备开始承担更复杂的推理任务。本地推理的价值并不抽象，主要体现在三个方面。第一，数据不出端可以减少隐私泄露风险。第二，弱网和离线场景仍然可以维持基本可用性。第三，交互链路缩短后，系统更容易控制首 token 时延和连续生成时延。对终端产品而言，这三点都比单纯追求峰值吞吐更重要。

与服务器不同，移动端的资源条件十分苛刻。内存容量有限，持续散热能力弱，操作系统调度策略也更偏向综合体验而不是单任务最优。在这样的环境下，CPU 仍然是最稳定、最通用的推理后端。一方面，CPU 不依赖专用驱动和额外框架，部署路径最短；另一方面，CPU 能覆盖更多机型，便于把推理能力落到真实产品中。MNN 之类的轻量推理框架因此具有很强的工程价值Jiang et al. (2020)。

但“能跑”不等于“跑得好”。移动端 CPU 往往采用异构多核结构，不同核心在频率、微架构和缓存层次上都存在明显差异。若仍沿用面向对称多核的线程划分方式，线程迁移、负载失衡和尾部阻塞就会频繁出现。对于交互式大模型推理，这些问题会直接表现为首 token 响应变慢、连续输出抖动增大，以及高负载场景下的性能不稳定。

1.1.2 异构多核 CPU 上的执行复杂性

现代手机 SoC 普遍采用 big.LITTLE 或更细粒度的多簇异构设计。大核追求高性能，中核兼顾性能和功耗，小核则更强调后台负载承载能力。对于同一个推理任务，不同核心完成相同计算量所需时间并不一致。若任务划分仍假定各线程处理速度近似相同，结果往往不是“所有线程同时结束”，而是少数线程拖尾、部分大核提前空闲。

除核心性能差异外，线程绑核与线程迁移也会显著影响执行结果。如果不做绑核，线程可能在多个核心之间切换。线程一旦迁移，缓存热数据会失效，局部性被打断，调度器还会引入额外切换开销。对于持续迭代执行的推理任务，这种开销会反复累积。在大模型推理中，单次额外开销也许不大，但在 Prefill 和 Decode 的多轮执行中会不断放大。

异构多核还带来另一个更隐蔽的问题：最佳线程数并不是固定常数。线程数过少，大核资源无法充分利用；线程数过多，又会引入同步、争用和调度开销。在真实手机上，这条关系常常表现为 U 型曲线。更重要的是，Prefill 和 Decode 的最优线程数并不相同。如果系统强行使用统一线程数和统一绑核策略，至少有一个阶段会偏离最优点。

1.1.3 MNN 默认执行方式下的工程瓶颈

本文研究建立在 MNN 框架之上。MNN 提供了较轻量的部署链路和较完整的 CPU 后端，是移动端本地推理中很有代表性的工业级开源框架 Jiang et al. (2020)。然而，在面向异构多核 CPU 的大模型推理场景下，MNN 的默认执行路径仍存在进一步优化空间。

首先，默认场景下并不会天然得到适合当前任务的绑核策略。若应用层没有显式指定 affinity，线程可能在运行过程中发生迁移，造成额外调度成本。其次，现有任务划分对核心性能差异的刻画仍然偏粗。固定性能比在某些模型和某些机型上可以工作，但当模型算子形态变化、输入规模变化或系统负载变化时，这种固定参数很容易失准。最后，在高负载环境下，若其他应用抢占部分核心，纯静态划分很难自我纠偏，尾部线程会阻塞整个推理流程。

本课题的直接动机并不是重新提出一套全新的调度理论，而是在真实手机、真实框架和无 root 约束下，把这些工程瓶颈逐项拆开，并给出可复现的改进路径。围绕这一目标，本文把研究问题收束到三个具体方向：分阶段线程数与绑核搜索、基于真实性能比的加权初始划分，以及 Prefill 阶段的无锁双端队列 work stealing。

1.2 研究动机与核心问题

1.2.1 绑核与线程数选择对性能的影响

在本课题的前期实验中，一个非常直接的现象是：绑核后的性能通常优于不绑核。这一现象并不难理解。绑定核心后，线程迁移次数下降，缓存局部性更稳定，运行时的调度扰动也更小。对于需要持续执行大量张量计算的推理任务，这些因素会共同转化为更短的执行时延。

但仅仅“绑核”还不够。继续沿着线程数维度观察，可以看到 Prefill 和 Decode 的性能都不是单调随线程数上升。线程数过小，异构核资源没有被充分利用；线程数继续增大后，划分粒度、同步开销和内存带宽争用开始抬头，性能又会回落。这使得“最佳线程数”成为一个必须通过实测确定的机型相关、阶段相关参数。

进一步地，Prefill 和 Decode 的最优点往往并不重合。Prefill 更像长任务批处理，强调总体吞吐和负载均衡；Decode 更像短步迭代，强调轻量调度和稳定延迟。若继续沿用统一线程数和统一 CPU 集合，系统很难同时兼顾两个阶段。因此，分阶段独立配置线程数和绑核掩码，成为本文系统设计的第一条主线。

1.2.2 固定性能比静态划分的局限

异构多核任务划分的核心问题是“如何估计不同线程的处理能力”。若能力估计不准，初始划分就会失衡。在 MNN 的现有实现中，针对计算密集型任务采用固定性能

比做静态分段是一种低成本方案，但它默认了不同机型、不同负载和不同模型下的核心相对速度具有稳定近似值。这个假设在真实手机环境中往往过强。

第一，核心的实际处理能力会受到 DVFS、系统温度和背景任务影响。第二，不同模型的算子组合并不相同，卷积主导、矩阵乘主导和访存主导的负载，对大小核的利用方式也不同。第三，即使同一模型，在 Prefill 和 Decode 两阶段中，算子形态和数据规模也会变化。固定性能比因此很容易出现“平均上看合理，具体到单次运行却不准”的问题。

这意味着，静态划分本身并不是问题，问题在于静态划分之前的能力估计必须更贴近真实设备。本文的第二条主线就是通过实测搜索得到更准确的核心性能比，用真实性能比替代固定经验值，再据此生成加权初始划分边界。

1.2.3 高负载场景下的阻塞与长尾问题

即便性能比估计更准确，纯静态划分仍然存在天然局限：它默认执行过程中不会出现明显扰动。这个假设在实验室空载环境下也许基本成立，但在真实手机上并不稳固。系统服务、界面刷新、后台同步和其他应用都可能竞争 CPU 时间片。当部分核心临时被抢占时，原先看似合理的静态任务边界会迅速变成负担。

Prefill 阶段尤其容易暴露这一问题。该阶段总任务量较大，只要一两个线程被明显拖慢，整个阶段结束时间就会被尾部线程锁住。换句话说，系统瓶颈不再是平均吞吐，而是最慢线程的完成时间。为此，本文引入基于无锁双端队列的 work stealing 机制：每个线程先执行自己的本地任务；当本地队列为空后，再尝试从其他线程任务尾部窃取剩余工作，以减轻拖尾。

与此相对，Decode 阶段的单步任务更短，调度机制不能太重，否则调度本身就会吃掉收益。因此，本文并不强求两阶段使用同一套策略，而是将 Prefill 设计为“加权初始划分 + work stealing”，将 Decode 设计为更轻量的动态任务获取。这种阶段感知设计，是本文区别于统一策略方案的关键。

1.3 本文工作与贡献

1.3.1 分阶段绑核与线程数启发式搜索

本文首先在真实手机平台上验证了绑核优于不绑核这一基本事实，并进一步观察到 Prefill 和 Decode 的性能随线程数增长呈现明显的 U 型关系。基于这一现象，本文在 MNN 推理流程中引入分阶段的线程数与 affinity 搜索机制，使 Prefill 和 Decode 可以分别使用不同的线程数和不同的 CPU 集合。

1.3.2 基于真实性能比的加权初始划分

针对固定性能比带来的初始任务划分偏差，本文通过实测搜索构建核心性能比，并据此生成加权初始划分边界。该方法不依赖抽象经验参数，而是直接以目标机型的实际执行表现为依据，从而使初始分工更贴近真实异构能力。

1.3.3 基于无锁双端队列的 Prefill work stealing 机制

针对高负载场景下纯静态划分容易产生长尾的问题，本文在 Prefill 阶段设计并实现了基于无锁双端队列的任务窃取机制。各线程先无锁执行本地任务，当本地任务耗尽时，再从其他线程任务尾部窃取剩余工作。该机制保持了静态划分的低开销优势，同时增加了对扰动和失衡的自适应修正能力Blumofe et al. (1999); Chase et al. (2005); Lê et al. (2013)。

1.4 论文组织结构

1.4.1 章节安排

第 1 章说明研究背景、工程问题和本文贡献。第 2 章介绍移动端异构多核 CPU、MNN 执行路径、Prefill 与 Decode 的阶段差异，并梳理 work stealing 与移动端推理调度相关工作。第 3 章给出系统设计与关键算法，包括分阶段绑核搜索、性能比标定、加权初始划分和 Prefill work stealing 实现。第 4 章在真实手机平台上完成性能与稳定性评估，并分析高负载场景下的调度行为。第 5 章总结全文并讨论后续工作。

1.4.2 写作定位说明

本文的重点是工程适配与系统验证，而不是构造新的调度理论。全文将尽量围绕“发现了什么瓶颈、为什么这样改、改动如何落到 MNN 中、实验结果说明了什么”这一主线展开，使论文论证与实际实现保持一致。

参考文献

- BLUMOF R D, LEISERSON C E. 1999. Scheduling multithreaded computations by work stealing[J]. Journal of the ACM, 46(5): 720-748.
- CHASE D, LEV Y. 2005. Dynamic circular work-stealing deque[C]//Proceedings of the Seventeenth Annual ACM Symposium on Parallelism in Algorithms and Architectures. 21-28.
- JIANG X, WANG H, CHEN Y, et al. 2020. MNN: a universal and efficient inference engine [Z/OL]. arXiv (2020). <https://arxiv.org/abs/2002.12418>.
- LÊ N M, POP A, COHEN A, et al. 2013. Correct and efficient work-stealing for weak memory models[C]//Proceedings of the 18th ACM SIGPLAN Symposium on Principles and Practice of Parallel Programming. 69-80.

武汉大学学位论文使用授权协议书

本学位论文作者愿意遵守武汉大学关于保存、使用学位论文的管理办法及规定，即：学校有权保存学位论文的印刷本和电子版，并提供文献检索与阅览服务；学校可以采用影印、缩印、数字化或其它复制手段保存论文；在以教学与科研服务为目的前提下，学校可以在校园网内公布部分或全部内容。

一、在本论文提交当年，同意在校园网内以及中国高等教育文献保障系统(CALIS)、高校学位论文系统提供查询及前十六页浏览服务。

二、在本论文提交 ☐ 当年 / ☐ 一年 / ☐ 两年 / ☐ 三年以后，同意在校园网内允许读者在线浏览并下载全文，学校可以为存在馆际合作关系的兄弟高校用户提供文献传递服务和交换服务。(保密论文解密后遵守此规定)

论文作者 (签名): _____

学号: _____

学院: _____

日期: 年 月 日